

## Sprawozdanie WSI ćwiczenia 2.

Treść zadania:

Zaimplementować klasyczny algorytm ewolucyjny z selekcją turniejową i sukcesją generacyjną, bez krzyżowania. Dostępny budżet to 10000 ewaluacji funkcji celu. Optymalizujemy funkcje numer 2 i 13 z CEC 2017 w 10 wymiarach. Ograniczenia kostkowe przestrzeni to -100, 100.

Liczbę iteracji algorytmu ewolucyjnego obliczam ze wzoru **budżet/(liczbę osobników)**.

Poniżej zamieszczam dane pomiarowe z doświadczeń dla różnej wielkości populacji i wartości parametru sigma, gdzie średnia była obliczana za każdym razem na podstawie 100 doświadczeń.

**Tabela dla sigma=0.5 i różnych wielkości populacji**  
**Funkcja f2**

wielkość populacji	min	max	średnia	odchylenie standardowe
2	230,04	21889,94	2326,72	4168,11
4	203,78	471,33	275,33	57,66
6	201,87	596,74	225,14	42,13
8	201,23	6514,3	279,29	627,65
12	200,65	5201,21	295,12	458,35
16	200,89	123532,65	1471,09	12270,68
25	200,34	2957198	296234	2342245

Patrząc na średnią otrzymanych wartości funkcji ze 100 doświadczeń najlepszą wartość (najniższą) otrzymała populacja składająca się z 6 osobników. Równocześnie uzyskując najniższe odchylenie standardowe 42,13. Świadczy to o stabilności wyników dla tej wielkości populacji, co oznacza, że mniejsze rozrzuty wartości funkcji wskazują na większą przewidywalność dla tej liczby osobników.


Następnie badam wpływ zmiany siły mutacji dla najlepszej znalezionej populacji, to jest 6 osobników.

**Tabela dla stałej liczby osobników równej 6 i różnych wartości sigma**  
**Funkcja f2**


sigma	min	max	średnia	odchylenie standardowe
0,2	201,01	4103164,21	43203,05	40810,6
0,5	201,87	596,74	225,14	42,13
1	251,11	23218,54	5017,21	5914,3
2	958	483026,71	73363,09	9846,21
3	10378	13194762	467322	1353254

Dla parametru sigma równego 0,5 populacja najlepiej znajduje minimum funkcji f2. Dodatkowo zamieszczam wykresy przedstawiające najlepsze wartości osobnika w populacji od iteracji w zależności od zadanej sigmy.


Wykres dla sigmy=0,2



Wykres dla sigmy=0,5



Wykres dla sigmy=3



Na wykresach widać, że wzrost parametru sigma znacząco wpływa na szybkość zmniejszania się wartości funkcji dla osobników na początku działania algorytmu. Lecz zbyt duża wartość sigma powoduje, że populacja ma większe trudności aby dotrzeć ostatecznie do globalnego minimum funkcji.

**Tabela dla  $\sigma=0.5$  i różnych wielkości populacji**  
**Funkcja f13**

wielkość populacji	min	max	średnia	odchylenie standardowe
2	2403,98	43843,33	15251,21	9590,34
4	2707,21	59275,54	21606,33	13410,31
6	2881,27	55291,53	18022,54	12484,71
8	3412,44	55726,22	22171,12	12993,63
12	1988,72	34423,32	5621,52	5145,29
16	3348,32	37698,76	20574,32	9735,25
25	1784,21	27836,34	10360,29	7873,87
40	4370,12	16929,81	8333,45	2775,21
50	3680,98	18533,62	8925,71	3831,13

Najniższą średnią wartość uzyskała populacja składająca się z 12 osobników. Jednak minimalną wartość funkcji ze wszystkich pomiarów uzyskała populacja z 25 osobnikami. Mimo to średnia wartość dla 12 osobników jest blisko dwukrotnie mniejsza niż dla 25 osobników.

Następnie badam wpływ zmiany siły mutacji dla najlepszej znalezionej populacji, to jest 12 osobników.

**Tabela dla stałej liczby osobników równej 12 i różnych wartości sigma  
Funkcja f13**

sigma	min	max	średnia	odchylenie standardowe
0,05	30401,38	5624807118	56282468	559657784
0,1	9702,75	15334,43	12081,34	1356,65
0,2	1943,32	3777,12	2623,82	427,22
0,5	1988,72	34423,32	5621,52	5145,29
1	2060,32	54775,53	17532,32	9604,32
2	3177,15	84358,32	32070,43	17362,22
3	5029,44	86182,21	31683,98	18456,83

Dla populacji o wielkości 12 osobników najlepsze wyniki uzyskano dla parametru sigma równego 0,2. Dla coraz większych wartości parametru (większych od 0,2) algorytm uzyskiwał wyniki z coraz większym odchyleniem standardowym a wartość znajdowanego minimum się zwiększała.

**Zwiększenie budżetu dla najlepszego doboru parametrów (wielkości populacji i sigmy)**

- Dla f2 wielkość populacji = 6 i sigma = 0,5

budżet	min	max	średnia	odchylenie standardowe
10000	201,87	596,74	225,14	42,13
50000	200,01	360,56	221,43	41,23

- Dla f13 wielkość populacji = 12 i sigma = 0,2

budżet	min	max	średnia	odchylenie standardowe
10000	1943,32	3777,12	2623,82	427,22
50000	1872,43	4501,65	2589,02	425,62

Po uzyskanych wynikach widać że zwiększenie dostępnego budżetu i tym samym zwiększenie liczby iteracji poprawia uzyskane wyniki algorytmu ewolucyjnego. Dla funkcji  $f2$  i zwiększonego budżetu = 50000 udało się znaleźć minimum globalne funkcji równe 200.

### **Wnioski:**

Algorytm dla odpowiednio dobranej liczby populacji i wartości parametru sigma, odpowiadającego za siłę mutacji osobników, potrafi znaleźć rozwiązanie blisko globalnego minimum funkcji, co udało się dla funkcji  $f2$  gdzie minimum globalne jest równe 200. W porównaniu do metody gradientu prostego działa on znacznie lepiej dla bardziej skomplikowanych funkcji. Sam algorytm nie jest trudny w implementacji, tym bardziej, że nie używamy mechanizmu krzyżowania między osobnikami a samo mutowanie i selekcję turniejową. Uzyskiwane wyniki dla pojedynczych uruchomień mogą się znacznie różnić, dlatego przy porównywaniu różnych parametrów startowych należy głównie patrzeć na uśrednione wyniki z kilkudziesięciu doświadczeń.